SISTEMA ANALÍTICO DE COMERCIO COLOMBIANO INTEGRADO CON INVENTARIO Y FACTURACIÓN.

CURSO DE ETL Y CIENCIA DE DATOS

PROYECTO FINAL

SEGUNDA ENTREGA

PRESENTADO POR:

RAUL ERNESTO DIAZ CUCHALA

GRUPO 2

PRESENTADO A:

FERNANDO BARRAZA ALVARADO

UNIVERSIDAD AUTONOMA DE OCCIDENTE

Cali, Valle del cauca

2026-1S

PROYECTO:

Sistema analítico de comercio colombiano integrado con inventario y facturación.

PROBLEMA:

En Colombia, las pequeñas y medianas empresas (PYMES) representan una parte fundamental del sector comercial y del desarrollo económico (Departamento Administrativo Nacional de Estadística [DANE], s. f.). Sin embargo, muchas de estas empresas gestionan sus procesos de ventas, inventario y facturación mediante herramientas básicas o sistemas independientes que no permiten integrar ni analizar de forma eficiente la información generada por sus operaciones. Esta situación dificulta la realización de análisis estratégicos y limita la toma de decisiones basada en datos en un entorno comercial que cambia constantemente.

Por otra parte, en el país existen diversas fuentes oficiales de información económica y empresarial, como los datos publicados por el Departamento Administrativo Nacional de Estadística (DANE) y los conjuntos de datos disponibles en el portal Datos Abiertos Colombia (DANE, s. f.; Gobierno de Colombia, s. f.). Estas fuentes incluyen información relevante sobre el comportamiento del comercio minorista, la clasificación de empresas por actividad económica (CIIU) y la organización territorial del país a través del sistema DIVIPOLA. Sin embargo, estos datos generalmente se analizan de forma independiente y no se integran con los sistemas que utilizan las empresas para registrar sus ventas, controlar inventarios o gestionar la facturación.

La falta de integración entre datos macroeconómicos, empresariales y territoriales con la información operativa de las empresas limita la posibilidad de realizar análisis más completos en el mercado. Como resultado, muchas PYMES no pueden comparar su desempeño con las tendencias reales del comercio, identificar oportunidades en determinadas regiones ni anticipar cambios en la demanda.

Ante esta problemática, este proyecto propone desarrollar un sistema analítico basado en un proceso ETL que permita integrar información proveniente de fuentes oficiales, datos empresariales y datos geográficos con información transaccional simulada de ventas, inventario y facturación. Esta información será consolidada en un Data Warehouse que facilite el análisis del comercio desde una perspectiva empresarial y territorial, permitiendo generar indicadores, identificar tendencias y apoyar la toma de decisiones estratégicas en las PYMES colombianas.

INVESTIGACIÓN ESTADO DEL ARTE:

Esta revisión permite identificar el estado actual de las investigaciones relacionadas con sistemas de analítica de datos, inteligencia de negocios y procesos de integración de datos en entornos empresariales. En particular, esta revisión se centra en estudios relacionados con Business Intelligence en PYMES, arquitecturas de Data Warehouse y ETL, uso de datos abiertos y sistemas de gestión de inventario y facturación, con el objetivo de identificar avances existentes, limitaciones y oportunidades de mejora.

Sistemas de Business Intelligence en PYMES

En los últimos años se han desarrollado diversas investigaciones sobre la implementación de sistemas de Business Intelligence (BI) en pequeñas y medianas empresas con el objetivo de mejorar la toma de decisiones empresariales. Estas herramientas permiten integrar información de diferentes áreas de la organización y transformarla en indicadores clave de desempeño (KPIs), dashboards y reportes analíticos que facilitan el análisis del negocio. Diversos estudios señalan que la analítica de datos y la inteligencia de negocios ayudan a mejorar la productividad, optimizar procesos y fortalecer la competitividad empresarial al permitir decisiones basadas en información confiable.

Sin embargo, a pesar de estos beneficios, la adopción de tecnologías de BI en las PYMES sigue siendo limitada debido a restricciones económicas, falta de infraestructura tecnológica y escasez de personal especializado. Además, muchas de estas soluciones fueron diseñadas para grandes organizaciones y suelen enfocarse principalmente en datos internos de la empresa, como ventas o inventario, sin integrar información externa del entorno económico. Esto evidencia la necesidad de desarrollar sistemas analíticos que combinen datos empresariales con información macroeconómica y territorial proveniente de fuentes oficiales.

Data Warehousing y procesos ETL

Las arquitecturas de **Data Warehouse** se han consolidado como componentes fundamentales en los sistemas de inteligencia de negocios, ya que permiten integrar grandes volúmenes de datos provenientes de múltiples fuentes en un repositorio centralizado orientado al análisis. En estas arquitecturas, los datos operativos de diferentes sistemas se organizan en modelos analíticos como el esquema estrella o el

modelo copo de nieve, lo que facilita la consulta, el análisis multidimensional y la generación de reportes estratégicos para apoyar la toma de decisiones.

Para alimentar estos repositorios se utilizan procesos **ETL (Extract, Transform, Load)**, los cuales permiten extraer datos desde distintas fuentes, transformarlos mediante procesos de limpieza, estandarización y validación, y cargarlos posteriormente en el Data Warehouse. Aunque estas arquitecturas se aplican ampliamente en distintos sectores, aún existen desafíos en su adaptación a contextos específicos, especialmente en economías emergentes o en entornos con datos heterogéneos. En el caso del comercio colombiano, se identifica una oportunidad de desarrollar modelos que integren datos macroeconómicos, empresariales y territoriales para generar análisis más completos del mercado.

Analítica del comercio y uso de datos abiertos

El crecimiento de los portales de datos abiertos gubernamentales ha permitido que investigadores, empresas y organizaciones accedan a grandes volúmenes de información pública relacionada con indicadores económicos, sociales y territoriales. En Colombia, entidades como el DANE y el portal Datos Abiertos Colombia ofrecen datasets sobre comercio minorista, actividad empresarial, población y estructura territorial, los cuales representan una oportunidad importante para desarrollar sistemas analíticos que permitan comprender el comportamiento del mercado y apoyar la planificación empresarial.

Sin embargo, a pesar de la disponibilidad de estos datos, diversos estudios señalan que su uso aún presenta limitaciones, ya que con frecuencia se analizan de forma aislada y no se integran con los sistemas productivos ni con los datos generados dentro de las empresas. Como resultado, el aprovechamiento de los datos abiertos en sistemas de inteligencia empresarial sigue siendo reducido, lo que evidencia la necesidad de desarrollar soluciones tecnológicas que integren datos públicos con información operativa empresarial para generar análisis más completos del comercio.

Sistemas de inventario y facturación en entornos empresariales

Los sistemas de gestión de **inventario y facturación** son herramientas ampliamente utilizadas por las empresas para registrar transacciones comerciales, controlar niveles de stock y generar documentos contables asociados a las ventas, permitiendo organizar y gestionar las operaciones diarias del negocio. Sin embargo, en muchos

casos estos sistemas funcionan únicamente como plataformas transaccionales y ofrecen capacidades limitadas de análisis, ya que los reportes generados suelen enfocarse en información histórica básica de ventas o inventario.

Además, la mayoría de estos sistemas no integra información externa relacionada con indicadores económicos o contextos regionales, lo que limita la posibilidad de realizar análisis estratégicos más completos. Por esta razón, surge la necesidad de desarrollar sistemas híbridos que combinen la gestión operativa de ventas, inventario y facturación con herramientas de analítica de datos e integración de información macroeconómica, permitiendo mejorar la planificación y la toma de decisiones en las empresas.

EXPLORACIÓN INICIAL DE DATOS

Realizamos un análisis de exploración de datos definiendo y cargando los datasets, los cuales se exponen en la siguiente tabla informativa:

BASE DE DATOS	DESCRIPCION	FORMATO	VARIABLES
Encuesta de Micronegocios Colombia (EMICRON)	Contiene información detallada de las unidades productivas, incluyendo ventas, ingresos, valor agregado, personal ocupado y características económicas (DANE, s. f.).	CSV 7500 index	• Ventas • Valor agregado • Ingreso mixto • Tipo de empresa • Ubicación
División Político-Administrativa de Colombia (DIVIPOLA)	Base de referencia que contiene los códigos oficiales de departamentos y municipios en Colombia (DANE, s.f.).	CSV 1122 index	• Código de departamento • Nombre del departamento
Clasificación Industrial Internacional Uniforme (CIIU)	Sistema de clasificación que organiza las actividades económicas en categorías estandarizadas (Naciones Unidas, 2008).	CSV 323 index	• Código CIIU • Descripción de la actividad económica
Índice de Precios al Consumidor (IPC)	Indicador económico que mide la variación de precios en el tiempo (inflación) (DANE, s. f.).	XLSX 86 index	• Año • Mes • Índice IPC
Producto Interno Bruto por Departamento (PIB)	Mide el valor total de la producción económica en cada departamento (DANE, s. f.).	XLSX 680 index	• Departamento • Año • PIB
Base de empresas registradas (EMPRESAS)	Contiene información empresarial como actividad económica (CIIU), tamaño de empresa y número de empleados.	9117 index	• CIIU • Tamaño de empresa • Personal

Estos datasets se integran para reconstruir el entorno económico colombiano, combinando información microeconómica (EMICRON), clasificación sectorial (CIIU), contexto geográfico (DIVIPOLA), variables macroeconómicas (PIB) y ajuste inflacionario (IPC), teniendo en mente estas relaciones se diseñó un modelo de datos tipo estrella, donde la tabla de hechos central (fact_emicron) concentra las métricas económicas principales, mientras que las tablas dimensión aportan contexto geográfico, sectorial, temporal y macroeconómico.

Este diseño permite un análisis eficiente y escalable, facilitando la integración de variables microeconómicas con indicadores macroeconómicos.

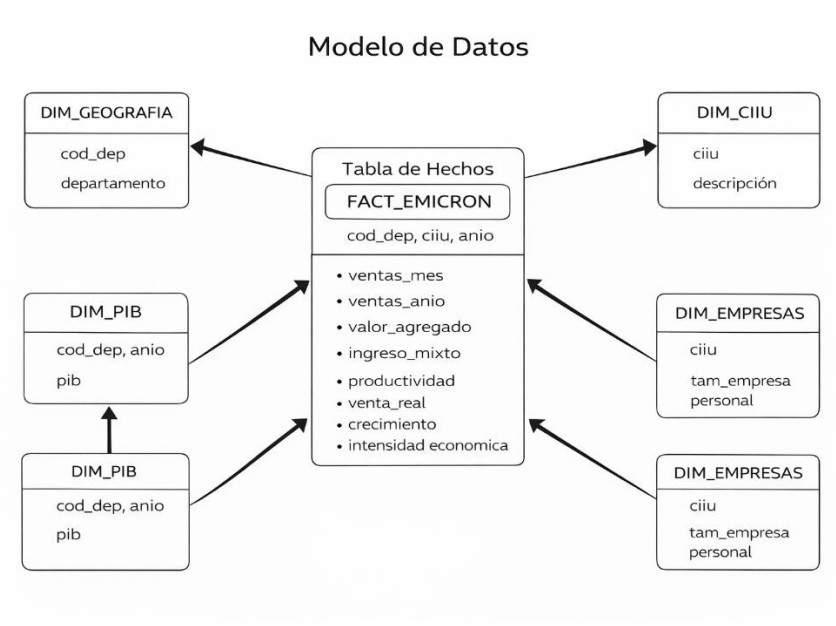

USO Y RESTRICCIONES DE LOS DATOS

Los datasets utilizados en este proyecto provienen de fuentes públicas como el Departamento Administrativo Nacional de Estadística (DANE) y el portal de Datos Abiertos Colombia. Estos datos se publican bajo esquemas de datos abiertos que permiten su acceso, reutilización y transformación para fines académicos, investigativos o de desarrollo. Sin embargo, su uso requiere citar adecuadamente la fuente original y respetar las condiciones de licencia abierta. Adicional, el usuario es responsable del uso adecuado de la información y de las interpretaciones derivadas del análisis. En el caso de los datos publicados por el DANE, estos cumplen con el principio de reserva estadística, por lo que la información se encuentra anonimizada y no permite identificar individuos o empresas específicas.

EXTRACCIÓN, TRANSFORMACIÓN Y VALIDACIÓN.

Extracción y estandarización inicial: Se inicia con el acondicionamiento de los datos

- Del dataset EMICRON se carga el dataset y se seleccionan las variables clave (Ventas, Valor agregado, Ingreso mixto, Actividad económica (CIIU) y Ubicación)
- En el dataset DIVIPOLA se cargan, seleccionan y renombran las columnas (Código departamento y nombre departamento), se eliminan los duplicados y se estandarizan los nombres.
- Del análisis de datos con el dataset CIIU, realizamos limpieza de nombres de columnas en minúsculas, sin espacios, realizamos la extracción del código CIIU que se encontraba en formato tipo "código ** descripción" y separamos la descripción
- El dataset IPC se carga como archivo xlsx y se renombran las variables año y numero de índice a ipc, acondicionamos el mes pasando de formato texto a numérico.
- El dataset PIB al igual que el anterior se carga como xlsx y se transforma de formato ancho a largo (melt), se limpian los años eliminando texto incluido
- Por último, para trabajar el dataset EMPRESAS, realizamos la limpieza y renombran las columnas, al igual que en dataset ciiu se realiza extracción de código CIIU y separación de descripción

Distribución de ventas

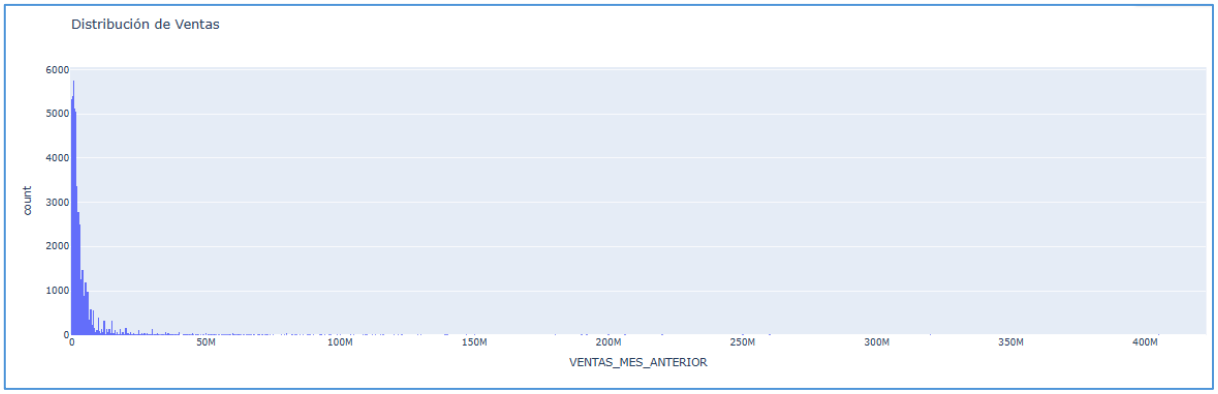

Se realizo un análisis de datos inicial de la distribución de ventas, en esta grafica podemos detallar que hay una concentración alta de 0 – 5 millones, y una cola extremadamente larga hasta 400 millones, podemos decir que la distribución de las ventas presenta un sesgo positivo, donde la mayoría de las unidades productivas reportan niveles bajos de ventas, mientras que un número reducido concentra valores significativamente altos, describiendo una economía conformada mayormente por microempresas y algunas empresas grandes dominan los ingresos.

Distribuciones logarítmicas de ventas

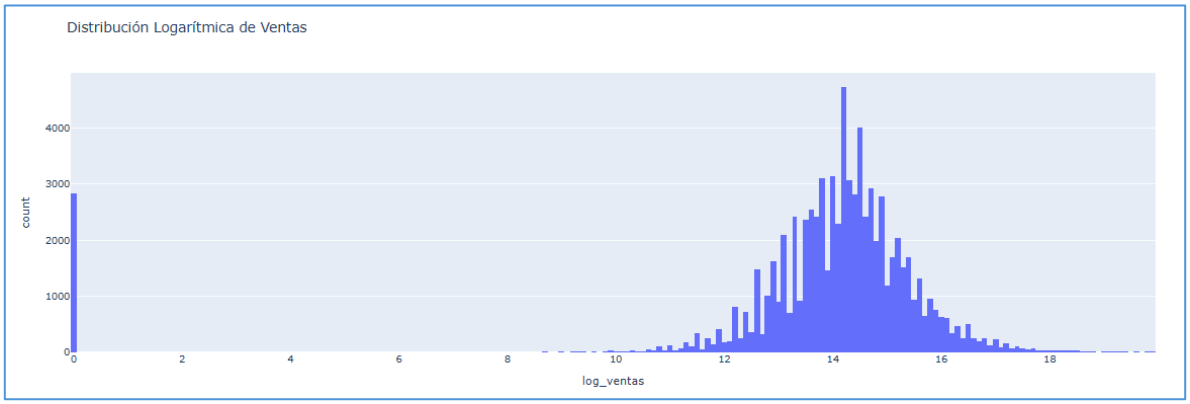

Dado los resultados en la distribución normal de las ventas, se realizó una distribución logarítmica, en estos resultados se puede ver que tiene forma de campana, esto indica que el logaritmo de las ventas se comporta bien, las ventas originales estaban sesgadas a la derecha por muchos valores pequeños y pocos valores grandes.

Outliers de ventas

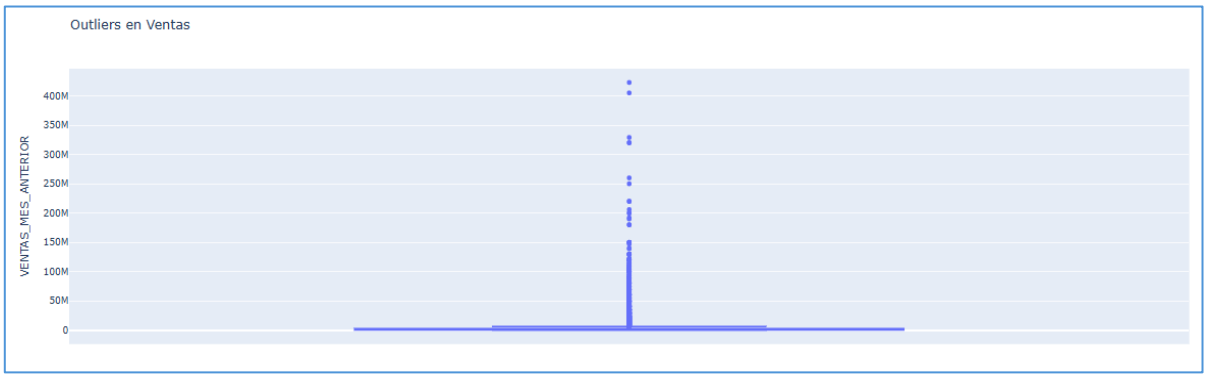

En la gráfica se pueden evidenciar muchos outliers y valores extremos hasta 400M, se observa una alta presencia de valores atípicos superiores, indicando una fuerte heterogeneidad en el comportamiento de las ventas, estos valores atípicos no deben ser eliminados, ya que representan unidades económicas con alta capacidad productiva y son fundamentales para el análisis.

Ventas totales por departamento

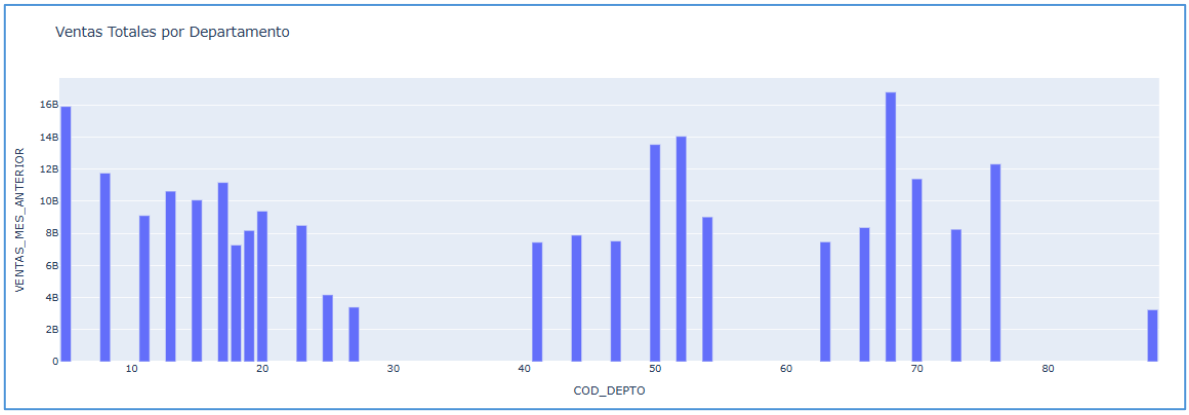

En general las ventas presentan una alta variabilidad entre departamentos, no hay una tendencia lineal sino más bien se observan picos y caídas, algunos departamentos concentran significativamente más ventas que otros.

Limpieza y depuración: continuando con el acondicionamiento de los datos y su transformación, realizamos la selección de variables construyendo un dataset base con (ventas, producción, tipo de empresa y sector económico), en este punto se eliminan valores nulos y las ventas iguales a 0 o menores

Tratamiento de outliers: se eliminan valores extremos conservando el 99% de los datos más representativos, se integran los de datos en JOINs y se construye un modelo tipo estrella

Creación de KPIs: realizamos feature engineering para la construcción de variables derivadas clave (Venta real ajustada por inflación, crecimiento, productividad, intensidad económica, total venta).

ANALISIS DE RESULTADOS OBTENIDOS DATASET FINAL

Ventas por departamentos

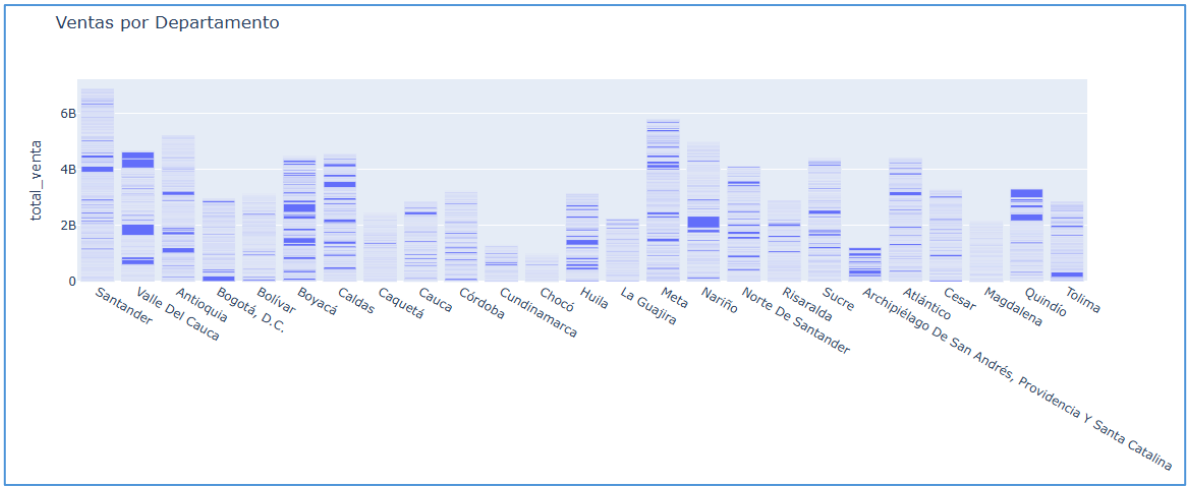

VENTAS vs PIB

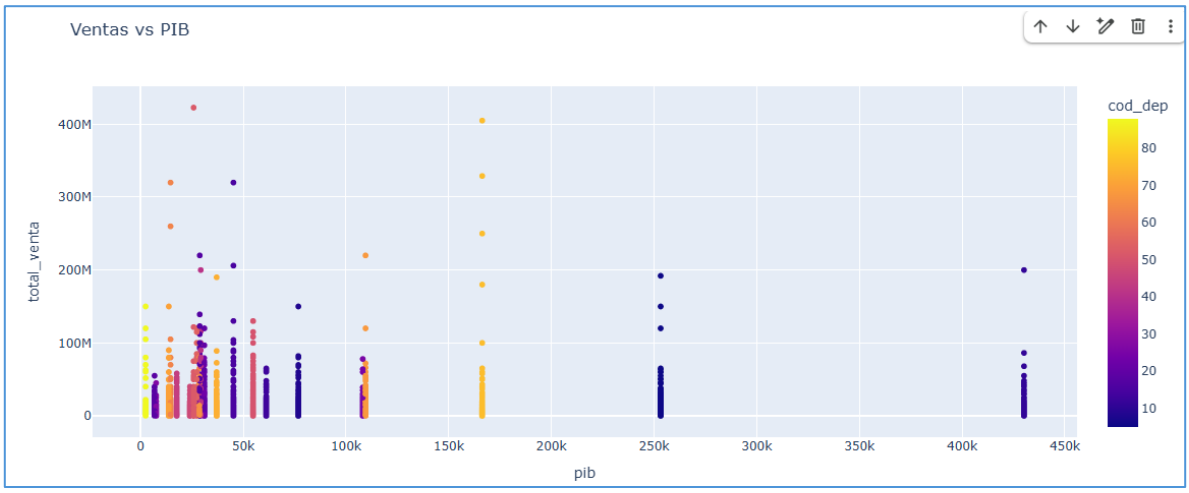

Los resultados obtenidos a partir del análisis de datos permiten generar información útil para la toma de decisiones en las pequeñas y medianas empresas (PYMES). El análisis de la distribución de ventas evidencia que la mayoría de las unidades productivas presentan niveles de ventas relativamente bajos, mientras que un número reducido concentra valores significativamente altos, lo cual permite comprender mejor la estructura del comercio. Asimismo, el uso de la transformación logarítmica facilita la interpretación estadística de los datos y la comparación entre empresas o sectores económicos. El análisis de valores atípicos (outliers) también permite identificar unidades productivas con niveles de ventas considerablemente superiores al promedio, lo que puede reflejar casos de alta productividad o concentración de actividad económica.

Por otra parte, el análisis de ventas por departamento muestra una marcada heterogeneidad regional, donde departamentos como Antioquia, Valle del Cauca y Bogotá concentran una mayor actividad comercial. Esta información puede ser útil para que las PYMES identifiquen regiones con mayor dinamismo económico y evalúen posibles oportunidades de expansión. Finalmente, el análisis de la relación entre ventas y PIB muestra que, aunque existe cierta influencia del contexto macroeconómico en el comportamiento de las ventas, este no es el único factor determinante. En conjunto, estos resultados demuestran que la integración de datos empresariales, territoriales y macroeconómicos mediante procesos ETL permite generar información estratégica que puede apoyar el análisis del mercado y la toma de decisiones empresariales.

REFLEXIONES FINALES

El desarrollo de este proyecto permitió evidenciar la importancia de integrar diferentes fuentes de información para comprender de manera más completa el comportamiento del comercio en Colombia. A través del proceso ETL fue posible extraer, transformar y consolidar datos provenientes de distintas fuentes oficiales, como indicadores macroeconómicos, información empresarial y datos territoriales, lo que permitió construir un conjunto de datos integrado orientado al análisis. Asimismo, la implementación de un modelo de datos tipo estrella facilitó la organización de la información y permitió realizar distintos análisis sobre la distribución de ventas, las diferencias regionales y la relación entre variables económicas como el PIB y el comportamiento de las ventas. Estos resultados evidencian la existencia de una alta heterogeneidad en el comercio colombiano, donde algunos departamentos concentran gran parte de la actividad económica mientras que otros presentan niveles de desarrollo más bajos. Finalmente, este proyecto demuestra que el uso de procesos ETL y arquitecturas de Data Warehouse puede ser una herramienta útil para integrar información económica y empresarial, permitiendo generar análisis más completos que apoyen la comprensión del mercado. Este tipo de soluciones analíticas puede contribuir a mejorar el acceso a información estratégica para las empresas y facilitar la toma de decisiones basada en datos en entornos económicos complejos.

REFERENCIAS

Departamento Administrativo Nacional de Estadística. (s. f.). Encuesta de Micronegocios (EMICRON). https://www.dane.gov.co

Departamento Administrativo Nacional de Estadística. (s. f.). División político-administrativa de Colombia (DIVIPOLA). https://www.dane.gov.co

Departamento Administrativo Nacional de Estadística. (s. f.). Índice de precios al consumidor (IPC). https://www.dane.gov.co

Departamento Administrativo Nacional de Estadística. (s. f.). Producto interno bruto por departamento. https://www.dane.gov.co

Gobierno de Colombia. (s. f.). Datos abiertos Colombia. https://www.datos.gov.co

Naciones Unidas. (2008). International Standard Industrial Classification of All Economic Activities (ISIC Rev.4). United Nations.